



Taller #1 - Regresión Lineal: Predicción del Peso de Halcones

Renata Araneda Díaz

Introducción

Estudiantes y profesores del Cornell College realizaron mediciones en halcones del refugio del lago MacBride, las que contemplaban las siguientes 6 variables:

- *Species*: tipo de especie (CH = Cooper's, RT = Red-Tailed y SS = Sharp-Shinned).
- *Wing*: longitud de la pluma primaria del ala desde la punta hasta la muñera (mm).
- *Weight*: peso corporal (g).
- *Culmen*: longitud de la parte superior del pico desde la punta hasta la parte carnosa del ave (mm).
- *Hallux*: longitud de la garra (mm).
- Medida relativa a la longitud de la cola (mm).

De ellas, se extrajeron muestras aleatorias para las tres especies, con el fin de proponer y validar un modelo de regresión múltiple que estime la variable *Weight* para los halcones, usando el resto de las variables como potenciales predictores. Se generaron y compararon tres modelos, y se verificó el cumplimiento de supuestos para el modelo elegido utilizando RStudio.

Metodología

Análisis exploratorio

Inicialmente, la base de datos contenía 908 observaciones de las 6 variables medidas en los halcones. Sin embargo, se eliminaron los datos de individuos a los que les faltaba la medición de una o más variables (correspondientes a NA). Esto se realizó para no alterar las operaciones y resultados futuros, ya que no aportarían información relevante en la formulación de los modelos y su posterior análisis. Para ello, se aplicó la función `drop_na()` sobre la base de datos en RStudio. Al eliminarlos, se obtuvo una base de datos con 891 observaciones de las 6 variables.

Para caracterizar las variables, por un lado, se calcularon estadígrafos para cada una de ellas (a excepción de *Species*, que es categórica). Para ello, se creó una tabla estadística utilizando la función `summarise` sobre la base de datos creada anteriormente (sin los NA). En dicha función se utilizaron argumentos tales como "`mean_wing = mean(Wing)`", "`sd_wing = sd(Wing)`" para obtener la media y desviación estándar (SD) de la variable *Wing*, por ejemplo. Se calcularon los estadígrafos: mínima, máxima, media, mediana y SD para las 6 variables, utilizando las funciones `min`, `max`, `mean`, `median` y `sd`. También, para ver las diferencias considerando la variable *Species*, se calcularon los estadígrafos para cada variable por especie. Se aplicó el mismo código anterior, pero se agrupó por dicha variable utilizando la función `group_by` antes de aplicar la función `summarise`. Por otro lado, se realizaron histogramas para observar la distribución de las variables, para lo cual se utilizó la función `ggplot`.

Para observar la relación entre variables, se construyó una matriz de correlación mediante la función `cor`. Dentro de ella, no se incluyó la variable *Species* al ser categórica. Además, se realizaron gráficos de correlación entre la variable dependiente *Weight* y el resto (independientes) diferenciando por especie, para ver cómo estaban distribuidos los datos respecto a ellas. Para ello se usó la función `ggplot2::ggplot`, agregando la función `scale_color_manual` para que los datos se diferenciaron según la especie. Relacionado a esto,



se graficó la frecuencia de datos por especie mediante la función *ggplot*, para ver si alguna predominaba por sobre las otras.

Comparación de modelos

Para seleccionar las variables que se incluirían en los modelos, se consideraron los resultados obtenidos en la matriz de correlación. Se construyeron 3 modelos utilizando la función *lm*, y posteriormente a ello, se aplicó la función *summary* a cada uno, con el fin de obtener datos relevantes como la significancia estadística (valor p) y el coeficiente de determinación múltiple ajustado (R^2 ajustado). Para comparar los modelos, se obtuvieron los valores de logaritmo de verosimilitud (*logLik*) y del Criterio de Información de Akaike (IAC) mediante la función *glance*. Sumado a ello, se calculó la raíz de error cuadrado medio (RMSE) utilizando la función *rmse*. Para visualizar las diferencias entre estos valores, se realizó una tabla comparativa.

Verificación de supuestos

Para el modelo elegido, se verificaron los supuestos de normalidad, homocedasticidad y autocorrelación respecto a los residuos. En primer lugar, se aplicó la función *shapiro.test* con el fin de realizar una prueba de normalidad Shapiro-Wilk, y se generó un gráfico cuantil-cuantil mediante la función *plot* para apoyar la verificación de este supuesto. En segundo lugar, se aplicó la función *bptest* para realizar una prueba de Breusch-Pagan y un gráfico de ubicación extendida (*Scale-Location*) para verificar la homogeneidad de varianza. En tercer lugar, se aplicó la función *dwtest* para realizar una prueba de Durbin-Watson y así verificar la independencia de los residuos. También, se calculó el grado de multicolinealidad usando el Factor de Inflación de la Varianza (VIF) mediante la función *car::vif*, el sesgo se calculó con la función *skewness*, el Error Cuadrático Medio (ECM) mediante la función *summarise*, y el Valor Absoluto del Residuo Promedio (MAD) con la función *mad*. Además, graficó la relación entre los residuales y los valores ajustados para ver la linealidad del modelo. Los gráficos se generaron con la función *plot*.

Resultados

Análisis exploratorio

En la Tabla 1 se muestran los estadígrafos de las variables cuantitativas. Es posible observar que entre los valores mínimos y máximos de las variables hay un amplio rango de datos. La media de las variables estaría fuertemente influenciada por estos valores extremos. En cuanto a la media y la mediana, la mitad de los datos de las variables está por sobre la media, a excepción de *Hallux*, que posee una mediana menor a la media. La variable *Weight* es la que posee mayor dispersión, seguido de *Wing* y luego *Tail*.

Tabla 1. Estadígrafos de cada variable cuantitativa medida para los halcones.

	Weight	Wing	Culmen	Hallux	Tail
Min	56	37,2	8,6	9,5	119
Máx	2030	480	39,2	341,4	288
Media	771,615	315,947	21,808	29,4	36,826
Mediana	970	370	25,5	26,413	214
DS	462,936	95,316	7,293	17,825	36,826



En la Tabla 2 se muestran los estadígrafos de cada variable diferenciando por especie. Se observa que, para todas las variables, la especie RT posee una media mayor, mientras que la especie SS posee la menor media. La desviación estándar de las variables no parece seguir este patrón. En cuanto a la media y mediana, se observa que, para la especie CH y RT, la mitad de los datos de todas las variables está por debajo de la media, mientras que para la especie SS no existe un patrón similar, ya que solo para la variable *Hallux*, la mitad de los datos se encuentran por debajo de la media.

Tabla 2. Estadígrafos de cada variable por especie de halcón.

		Species		
		CH	RT	SS
Weight	Min	56	101	85
	Máx	1119	2030	1094
	Media	419,62	1.094,84	148,16
	Mediana	375	1070	155
	DS	163,06	189,70	80,75
Wing	Min	145	37,2	143
	Máx	377	480	370
	Media	244,14	383,63	184,88
	Mediana	240	384	191
	DS	32,13	31,26	22,56
Culmen	Min	12,2	15,7	8,6
	Máx	25,4	39,2	27,3
	Media	17,56	26,97	11,47
	Mediana	17,1	26,8	11,7
	DS	2,41	2,05	1,91
Hallux	Min	13,8	10,3	9,5
	Máx	54,5	341,4	143
	Media	22,68	32,01	14,97
	Mediana	21,3	30,8	13,9
	DS	5,34	17,77	14,02
Tail	Min	157	122	119
	Máx	233	288	221
	Media	200,96	222,13	146,68
	Mediana	200	221	150
	DS	18,01	14,60	15,72

En la Figura 1 se observa la distribución de las variables. Para la mayoría de ellas existe asimetría en la distribución, ya que los datos se concentran en dos zonas, a excepción de *Hallux*, en la cual solo se concentran en un rango de valores muy marcadamente. Además, tanto para *Wing*, *Culmen* y *Tail*, se observa que los datos están mayormente concentrados hacia la derecha,



en valores superiores. Para *Weight* ocurre algo similar, aunque también existe una gran cantidad de datos en valores más inferiores de la variable.



Figura 1. Distribución de las variables cualitativas medida para los halcones.

En la Tabla 3 se presenta la matriz de correlación para las variables. Respecto a ello, *Hallux* es la variable que menos se correlaciona con el resto, y *Culmen* es la que posee una mayor correlación con las demás. En cuanto a *Weight*, las variables que más se correlacionan con ella corresponden en primer lugar a *Culmen*, seguido de *Wing* y luego *Tail*.

Tabla 3. Matriz de correlación entre las variables.

	Wing	Weight	Culmen	Hallux	Tail
Wing	1	0,9347	0,9587	0,4333	0,8998
Weight	0,9348	1	0,9534	0,4299	0,8746
Culmen	0,9587	0,9534	1	0,4409	0,9142
Hallux	0,4333	0,4299	0,4409	1	0,4143
Tail	0,8998	0,8746	0,9142	0,4143	1

En la Figura 2 se observa que los datos tienen una clara tendencia dependiendo de la especie. Además, la especie RT muestra una mayor dispersión en sus observaciones, al contrario de la especie SS, en que sus datos se muestran más agrupados. La relación entre la variable *Weight* y las variables *Wing*, *Culmen* y *Tail* pareciera ser exponencial. En contraste a ello, el gráfico para la variable *Hallux* muestra que, para distintos pesos (*Weightk*), sus valores suelen ser similares, ya que los datos se encuentran muy concentrados en un rango determinado.



Figura 2. Gráficos de correlación entre la variable dependiente *Weight* y cada una de las independientes.

La Figura 3 muestra la frecuencia de datos por especie. Se observa una clara predominancia de la especie RT por sobre las otras. Además, la especie CH es la que tiene la menor frecuencia en observaciones. Esto quiere decir, que fueron muestreados más individuos de halcones de la especie RT, y una cantidad muy inferior de individuos de halcones de la especie CH.




Figura 3. Frecuencia de datos por especie.

Comparación de modelos

Los modelos se construyeron considerando las variables que mostraban una mayor correlación con la variable *Weight*. Se descartó la variable *Hallux* por mostrar una baja correlación y una distribución de sus datos muy sesgada a un rango de valores específico, razón por la cual no aportaría en gran medida en la estimación de *Weight* mediante un modelo. Se seleccionaron las variables *Culmen*, *Wing* y *Tail* para construir el primer modelo, ya que eran las que estaban más correlacionadas con *Weight*. Para comparar, en el segundo modelo se utilizaron las variables *Culmen* y *Tail*, y en el tercer modelo las variables *Culmen* y *Wing*.

Para cada modelo se obtuvo un resumen estadístico. En cuanto al primero (Tabla 4), tanto las variables *Culmen* y *Wing* son estadísticamente significativas, por lo que inciden sobre la



estimación de la variable respuesta *Weight*. Por el contrario, la variable *Tail* no es estadísticamente significativa.

Tabla 4. Estimación de los coeficientes y significancia estadística de cada variable para el modelo 1.

	Estimado	Error estándar	Valor t	Pr(< t)	
Intercepto	-597,426	33,223	-17,440	< 2E-16	***
Culmen	45,608	2,410	18,918	< 2E-16	***
Wing	1,276	0,171	7,545	2,16E-13	***
Tail	-0,236	0,311	-0,76	0,448	

En cuanto al segundo modelo (Tabla 4), solamente la variable *Culmen* resulta estadísticamente significativa para estimar la variable *Weight*.

Tabla 5. Estimación de los coeficientes y significancia estadística de cada variable para el modelo 2.

	Estimado	Error estándar	Valor t	Pr(< t)	
Intercepto	-571,068	34,209	-16,693	< 2E-16	***
Culmen	59,436	1,586	37,474	< 2E-16	***
Tail	0,233	0,314	0,743	2,12E-13	

Para el tercer modelo (Tabla 5), tanto la variable *Culmen* como *Wing* son estadísticamente significativas.

Tabla 6. Estimación de los coeficientes y significancia estadística de cada variable para el modelo 3.

	Estimado	Error estándar	Valor t	Pr(< t)	
Intercepto	- 601,537	16,032	-37,520	< 2E-16	***
Culmen	44,846	2,192	20,459	< 2E-16	***
Wing	1,250	0,167	7,456	2,12E-13	***

En la Tabla 7, se muestran algunos criterios utilizados para comparar los tres modelos mencionados. Es posible observar que, en base al R^2 ajustado, el modelo 2 es el que explica un menor porcentaje de la variabilidad en la variable respuesta *Weight*. Al contrario, el modelo 3 es el que explica una mayor proporción, aunque posee un coeficiente similar al modelo 1.

Respecto a logLik, el modelo 1 es el que mejor se ajusta a los datos, ya que posee el menor valor de este criterio, por lo que en el modelo queda una menor variabilidad sin explicar. Sin embargo, esto podría deberse al hecho de que en el modelo 1 se incluye una variable más que en los otros modelos.

En cuanto a los valores de AIC, el modelo 3 es el que se ajusta mejor a los datos considerando su complejidad. En tanto, el modelo 2 es el que se ajusta peor a los datos, y el modelo 1 tiene un ajuste similar dada la proximidad de los valores para el criterio.

En cuanto al RMSE, el modelo que es más preciso para predecir la variable *Weight* es el primero, aunque también posee un valor similar al modelo 3. Por el contrario, el modelo 2 es el que peor se ajusta a los datos.



Tabla 7. Criterios de comparación entre los modelos.

Criterio	Modelo 1	Modelo 2	Modelo 3
R² ajustado	0,9140	0,9087	0,9141
logLik	-5637,808	-5664,873	-5638,098
AIC	11285,62	11337,75	11284,2
RMSE	135,445	139,622	135,489

En base a la comparación, el modelo 2 es el que tiene un peor ajuste para los datos, además de incluir dos variables, siendo una de ellas no estadísticamente significativa para la estimación (Tail). Se selecciona el modelo 3 como el mejor de los tres, ya que, en base algunos criterios descritos (como el R² ajustado o el AIC) es el que tiene un mejor desempeño frente a la estimación de la variable respuesta, considerando su ajuste a los datos y su complejidad. Además, aunque para algunos criterios (como RMSE y logLik) el modelo 1 sea indicado como el que mejor se ajusta a los datos, este contiene una variable adicional que no aporta en la estimación, ya que no es estadísticamente significativa.

Verificación de supuestos

Normalidad de los residuos

En la Figura 4 se muestra que, a pesar de que una gran cantidad de residuos se sitúan a lo largo de la línea punteada, hay valores que salen de ella a los extremos. Esto indicaría problemas con la normalidad. Sumado a ello, a partir de la prueba de normalidad de Shapiro-Wilk, se obtuvo un valor de p menor a $2,2E-16$ para el modelo 3. Esto indica que los residuales no siguen una distribución normal, ya que se rechaza la hipótesis nula de la prueba (que la distribución sea normal), debido al que el valor p es menor al nivel de significancia de 0,05.




Figura 4. Gráfico cuantil-cuantil para el modelo 3.

Homogeneidad de varianzas

A partir de la prueba de Breusch-Pagan, se obtuvo un valor p igual a $7,422E-08$ para el modelo 3. Esto indica que las varianzas de los residuos probablemente no cumplen con el supuesto de homogeneidad de varianza, ya que se rechaza la hipótesis nula de la prueba (las varianzas de los residuos son homogéneas), debido al que el valor p es menor al nivel de significancia de 0,05. Además, en la Figura 4 se observa que la dispersión de los residuos no es



igual en todos los valores ajustados, además de que no se dispersan aleatoriamente alrededor de la línea roja. Se destaca la concentración de datos ajustados entre los valores 1000 y 1300 aproximadamente. Esto comprobaría que los residuos no cumplen con el supuesto de homocedasticidad.




Figura 5. Gráfico de ubicación extendida (Scale-Location) para el modelo 3.

Independencia de los residuos

A partir de la prueba Durbin-Watson, se obtuvo un valor del estadístico Durbin-Watson (DW) entregado por la prueba fue de 1,9072, el cual es cercano a 2, lo que indica que no hay autocorrelación significativa. Además, se obtuvo un valor p igual a 0,08124 bajo la hipótesis alternativa de que la autocorrelación es mayor que cero (que existe correlación positiva). Dado que el valor p es mayor que el nivel de significancia 0,05 usualmente usado, no es posible rechazar la hipótesis nula (que no existe correlación positiva).

Multicolinealidad

A partir del el Factor de Inflación de la Varianza calculado para las variables del modelo, se obtuvo un 12,34872 tanto para *Culmen* como para *Wing*, lo que indica niveles críticos de multicolinealidad, es decir, se encuentran altamente correlacionadas.

Sesgo, Error Cuadrático Medio (ECM) y Valor Absoluto del Residuo Promedio (MAD)

Se obtuvo un valor de 0,0696 para el sesgo, el cual al ser positivo indica que la distribución está sesgada hacia la derecha, es decir, hacia valores altos de la variable respuesta. También, se obtuvo un ECM de 87,1, por lo que hay una diferencia promedio de 87,1 g² entre los pesos estimados por el modelo y los pesos observados en los halcones. Además, el MAD calculado fue de 85,25, lo que significa que los pesos estimados por el modelo se desvían en promedio 85,25 g de los pesos observados.

En cuanto a la linealidad del modelo, en la Figura 5, se observa que no presenta linealidad, ya que la línea roja se curva levemente alrededor del valor cero de los residuales. Además, no se distribuyen aleatoriamente ni de forma homogénea alrededor de la línea roja (los residuales no cumplen con el supuesto de homocedasticidad). Se destaca una gran cantidad de datos en valores superiores de la estimación (entre 1000 y 1300), y que prácticamente no hay datos entre los valores 700 y 900 aproximadamente.




Figura 5. Relación entre los residuales y los valores ajustados.

Conclusión

La variable *Tail* resultó no ser significativa para ninguno de los modelos que la incluía. De todos los modelos propuestos, el que incluye las variables *Culmen* y *Wing* es el que mejor explica la variabilidad de los datos. Sin embargo, los residuales no cumplen supuestos relevantes como la normalidad y homogeneidad de varianza. Además, no se pudo determinar la independencia de los residuos porque no se rechazó la hipótesis alternativa de la prueba realizada. Para futuros modelos, se deberían realizar transformaciones de datos para que los residuales cumplan con dichos supuestos.

En contraste al primer modelo, con el tercero se evitaría destinar recursos de forma innecesaria a la medición de una variable que no aporta en la estimación de *Weight*. Además, supone un menor esfuerzo de muestreo, y una menor probabilidad de error al momento de medir variables, ya que solo se concentraría la atención en dos de ellas (*Culmen* y *Wing*).

Es importante destacar que, en la base de datos, hubo muchas más observaciones de la especie RT comparado con las demás especies, lo que puede sesgar las estimaciones que realiza el modelo elegido. Esta especie parece tener longitudes mayores para las variables medidas, comparado con el resto. Además, es posible observar en los gráficos de correlación de las variables por especie que existe una relación más bien exponencial para los datos observados, y que estos se encuentran muy agrupados por especie. Por esta razón, sería interesante incluir la variable *Species* dentro del modelo, para así estimar de manera más precisa la variable respuesta, considerando la tendencia que siguen los datos según cada una.