



Taller #3 - Aprendizaje Supervisado / Clasificación

Renata Araneda

Introducción

Considerando el evento histórico por el cual atravesaron los pasajeros del Titanic, resulta interesante pensar en alguna forma en que esta tragedia se podría haber evitado o generado los menores daños posibles a la tripulación. En base a esto, los modelos de clasificación supervisada pueden ser una herramienta útil para analizar datos de los pasajeros que abordaron este barco, y predecir qué personas probablemente no iban a sobrevivir, con el fin de evitar la mayor parte de las pérdidas humanas. El objetivo de este taller es proponer y validar un método que permita predecir la sobrevivencia de los pasajeros del Titanic sobre a base de todas o algunas de estas variables.

Metodología

Se analizó descriptivamente las variables en el dataset, con el fin de identificar valores ausentes y preparar los datos para etapas posteriores. También se realizó un análisis exploratorio para observar cómo se comportan ciertas variables en función de otras. Se seleccionaron las variables consideradas como las más relevantes para ajustar los modelos. El dataset se dividió utilizando el método Cross-validation en los conjuntos de datos de entrenamiento (80%) y de testeo (20%). A partir del entrenamiento, se ajustaron los modelos y se obtuvieron métricas para comparar y seleccionar uno de ellos.

Resultados

Datos: Estadística descriptiva

El dataset “titanic” contiene información respecto a los pasajeros debidamente inscritos que abordaron este barco. Posee 891 observaciones de doce variables, correspondientes a PassengerId (id del pasajero), Survived (sobrevivencia), Pclass (clase), SibSp (número de hermanos o cónyuge a bordo), Parch (número de padres o hijos a bordo), Sex (sexo), Age (edad), Fare (precio), Name (nombre), Ticket (boleto), Cabin (cabina) y Embarked (embarcación). Estas últimas cuatro variables no se consideraron en la descripción del dataset ni en etapas posteriores, ya que los datos eran específicos para cada pasajero.

La Figura 1, muestra que las variables SibSp, Parch y Fare poseen la mayor parte de sus datos sesgados hacia menores valores en su distribución. Solo los datos en Age están distribuidos de forma más simétrica respecto a la mediana. Para esta variable, se obtuvo una mediana de 28 años, con una media de 29,7, un mínimo de 0 y máximo de 80. En cuanto a la Figura 2, se observa que la mayor parte de los pasajeros no sobrevivieron, hubo más en tercera clase, la mayoría era hombre y el puerto S fue en donde más embarcaron personas.




Figura 1. Boxplots de las variables Age, SibSp, Parch y Fare.




Figura 2. Frecuencia de individuos según las variables Survived, Pclass, Sex y Embarked.

En total había 866 datos ausentes, correspondientes a las variables Cabin (687), Age (177) y Embarked (2). Estos últimos dos datos faltantes se imputaron por la moda de Embarked, y, dado que había una proporción del 19,8% de datos faltantes de Age, se optó por realizar imputación también según otras variables (Useche y Mesa, 2006), en este caso Pclass y Sex. Esto se hizo para no eliminar estas observaciones y perder información que puede ser valiosa en etapas posteriores. Al realizar esto, se observa en la Figura 3 que los datos no cambiaron su distribución, sino que solo aumentó la frecuencia de las observaciones en los imputados, y la media pasó de 29,7 a 29,32. Por esta razón, tanto la estadística exploratoria como el ajuste y comparación de modelos se realizó considerando el dataset con los datos de edad imputados.




Figura 3. Comparación de los histogramas de edad para el dataset con datos imputados (Imputada) y sin datos imputados (Sin imputar).

Datos: Estadística exploratoria

Respecto a las variables categóricas, en la Figura 4 se observa que la proporción de pasajeros sobrevivientes cambia según la clase y sexo. Sin embargo, la proporción de sobrevivientes no varía de esta forma según la variable Embarked, ya que hay un porcentaje de sobrevivientes similar para los puertos Q y S.



Figura 4. Proporción de supervivencia y no supervivencia en el titanic según las variables Pclass, Sex y Embarked.

En la Figura 5, se observa que para las variables Fare, Parch y SibSp la distribución se encuentra sesgada hacia valores menores en su distribución, incluso al considerar la supervivencia y el sexo. Para Age, no hay un cambio en la distribución al considerar estas últimas dos variables, ya que la mediana en los supervivientes es similar, sea hombre o mujer, y en los no supervivientes, la edad de las mujeres fue menor que la de los hombres, pero la distribución para ambos sexos es similar.




Figura 5. Boxplots de las variables Age, Fare, Parch y SibSp según supervivencia y sexo.

Dada la variación en proporción de supervivientes y no supervivientes para las variables Sex y Pclass, y el hecho de que el resto no posea diferencias en los datos que permitan discriminar según la supervivencia, es que se seleccionan las primeras dos variables mencionadas para ajustar los modelos.



Ajuste y comparación de modelos

Se ajustaron los modelos de clasificación supervisada K-NN, bayes ingenuo y regresión logística (logit) con las variables Sex y Pclass del conjunto de datos de entrenamiento.

A partir del valor de Accuracy según distintos valores de k en el modelo K-NN, se obtuvo que el valor óptimo corresponde a 13 (Figura 6), es decir, el modelo predice la sobrevivencia con mayor exactitud (Accuracy) considerando los 13 vecinos más cercanos.




Figura 6. Accuracy según los distintos valores de k para el modelo K-NN.

En la Tabla 1 se observa que los coeficientes Intercept, Sex (male), Pclass (2) y Pclass (3) fueron significativos para el modelo de regresión logística, con una significancia estadística mayor a 0,05.

Tabla 1. Coeficientes significativos del modelo de regresión logística.

Variable	Coeficiente	Error Estándar	Valor z	Valor p
Intercept	2.345	0.247	9.486	2.39e-21
Sex (male)	-2.781	0.210	-13.240	5.14e-40
Pclass (2)	-0.772	0.274	-2.813	4.90e-03
Pclass (3)	-1.943	0.247	-7.876	3.39e-15

Para el modelo de bayes ingenuo, las probabilidades a priori de sobrevivencia es de 0,38 y la de no sobrevivencia es de 0,61. Dado que se usaron predictores del tipo categórico (Sex y Pclass) no se obtuvo la media y desviación estándar por clase para cada uno.

En la Tabla 2 se muestran la matriz de confusión para cada modelo. Respecto a esto, el modelo de bayes clasificó solo el 0,6% de los no sobrevivientes (clase 0) como sobrevivientes (clase 1), y el 27,1% de los sobrevivientes como no sobrevivientes. El modelo de regresión logística clasificó el 19,8% de las observaciones de la clase 0 como si fueran de la clase 1, y el 11,9% de la clase 1 como si fueran de la clase 0. El modelo K-NN tuvo la mayor proporción de clasificación de clase 1 como clase 0 (29,4%) y un valor menor (4,0%) en la clasificación de la clase 0 como clase 1.

Tabla 2. Matrices de confusión para los modelos de clasificación supervisada ajustados.

Clase	Bayes ingenuo		Regresión logística		Modelo K-NN	
	0	1	0	1	0	1
0	61,0	27,1	41,8	11,9	57,6	29,4
1	0,6	11,3	19,8	26,6	4,0	9,0



El modelo que obtuvo una mayor Accuracy promedio fue el de bayes ingenuo, con un valor de 0,723, el modelo logístico obtuvo un Accuracy promedio de 0,683, y el modelo K-NN tuvo un Accuracy promedio de 0,666, siendo el menor de los tres. En cuanto al Kappa, el modelo de bayes ingenuo obtuvo un valor promedio cercano a 0,4, al igual que el modelo logístico. Mientras que el valor promedio para K-NN es el menor, y está mucho más cercano a 0,2 (Figura 7).




Figura 7. Accuracy y Kappa según cada modelo (NB = Bayes ingenuo, KNN = modelo K-NN, LOG = Regresión Logística).

En la Figura 8 se muestran las curvas ROC de cada modelo. La regresión logística obtuvo un área bajo la curva de 0,76, al igual que para el modelo K-NN. Sin embargo, para el modelo de bayes ingenuo, se obtuvo un área de 0,64.




Figura 8. Curvas ROC para los modelos logístico (1), K-NN (2) y Bayes ingenuo (3).



Discusión

El hecho de solo seleccionar dos variables (Pclass y Sex) para ajustar los modelos, en vez de todas las variables, es mucho más práctico en cuanto al esfuerzo de muestreo que se debe hacer para recolectar los datos. Sin embargo, es probable que haya variables que podrían servir para realizar este análisis pero que no están consideradas en este dataset, como el hecho de que alguna persona estuviera enferma o tuviera problemas de movilidad, por ejemplo, lo cual podría disminuir su probabilidad de sobrevivencia al no tener tanta agilidad como el resto de los pasajeros.

En cuanto al modelo K-NN, el hecho de probar distintos valores de k muestra que no hay un patrón en el cual al aumentar el k aumente la exactitud. Pese a que el modelo predice con mayor exactitud cuando considera a 13 vecinos más cercanos, también se obtiene un valor alto de Accuracy cuando clasifica con tan solo los 5 vecinos más cercanos. Sin embargo, clasificar considerando solo los 5 vecinos más cercanos podría generar un sesgo en la clasificación, induciendo un sobreajuste al no considerar toda la variabilidad que puede haber en el resto de los datos, pues considerar 13 observaciones podría poseer más variación que tan solo 5 en cuanto a otras variables.

El modelo que mostró el mayor Accuracy a partir del ajuste fue el bayes ingenuo, indicando que es el que tiene una mayor razón de clasificación correcta, tanto para sobrevivientes como no sobrevivientes, comparado con el modelo logístico y el K-NN. Es decir, este modelo predice con mayor frecuencia la sobrevivencia de forma correcta en comparación al resto. En cuanto al Kappa, el valor promedio para Bayes ingenuo y la regresión logística, al encontrarse cercano a 0,4, se indica un grado de acuerdo mediano con los resultados reales (Landis & Koch, 1977), siendo mayor que el grado de acuerdo que se produce con el modelo K-NN.

En cuanto a las curvas ROC, el área bajo la curva del modelo bayes ingenuo fue la menor (0,64) comparada al resto de modelos (0,76 para logístico y K-NN). Esto sugiere que, al estar cercano a 0,5, este modelo es el menos discriminativo, mientras que el resto son más discriminativos al tener un área más cercana a 1, es decir, aunque bayes ingenuo muestre una mayor exactitud en la predicción, este modelo posee la menor posibilidad de clasificar correctamente a individuos seleccionados al azar (Martínez y Pérez, 2022).

Es importante considerar la limpieza y procesamientos de datos realizados, y la posterior división de los conjuntos de datos, ya que esto puede generar diferencias en los resultados que se obtienen para las distintas métricas de los modelos, e incluso para el ajuste de los modelos en sí, lo cual es determinante al momento de seleccionar uno de los modelos como el que predice de manera más adecuada la sobrevivencia, en este caso. La selección también puede variar en base a la métrica utilizada para ello. Para efectos de los modelos ajustados, si se considera la exactitud, el modelo seleccionado sería bayes ingenuo, sin embargo, posee sus limitaciones respecto a cómo clasifica individuos seleccionados al azar, razón por la cual quizás debería entrenarse con una mayor cantidad de datos para obtener un panorama más general de lo que sucedió con los pasajeros.



Pontificia Universidad Católica de Chile
Facultad de Agronomía y Sistemas Naturales
Departamento de Ecosistemas y Medio Ambiente

Referencias bibliográficas

Martínez, J. y Pérez, P. (2022). La curva ROC. *Medicina de familia*, 46. <https://static.elsevier.es/ficheros/7.pdf>

Useche L. y Mesa, D. (2006). Una introducción a la imputación de valores perdidos. *Terra nueva estepa*, 21(31), 127-151. <https://www.redalyc.org/pdf/721/72103106.pdf>

Landis J. & Koch G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33, 159-174.