

Taller 4 - Aprendizaje No Supervisado

Renata Araneda Díaz

2024-06-27

Introducción

Los Métodos de Clasificación No Supervisada son algoritmos pertenecientes al *Data Mining*, los cuales permiten descubrir patrones y tendencias en los datos basándose en una serie de variables que los describen (Rodríguez y Díaz, 2009). Este tipo de exploración es útil para descubrir similitudes entre observaciones y generar a partir de ello un grupo (*cluster*) (Tyagi *et al.*, 2022). Existen distintos métodos que se pueden utilizar para realizar el agrupamiento de observaciones. Entre ellos se encuentran el *clustering* jerárquico y el *k-means*, los cuales se basan en “un algoritmo basado en la distancia para medir la distancia entre los clústeres” (Belyadi & Haghighat, 2021). En este taller, la clasificación no supervisada se utiliza con el objetivo de validar un método que permita separar las canciones en grupos usando algún algoritmo de clustering o aglomeramiento.

Metodología

Se utilizó el dataset “*spotify*” que contenía una serie de variables cuantitativas en relación a canciones de la plataforma. El conjunto de datos fue normalizado para que todas las variables tuvieran la misma escala, con valores entre 0 y 1, y de esta manera la distancia euclidiana calculada al aplicar los métodos no se distorsionara por su magnitud (Hernández y Rodríguez, 2008). Se realizó un análisis previo (pre-proceso) de los datos, del cual se obtuvo la estadística descriptiva y exploratoria, con el fin de verificar la presencia de outliers mediante boxplots y las correlaciones entre las variables mediante una matriz de correlación.

Se compararon dos métodos de clasificación no supervisada, correspondientes a un método de **clustering jerárquico** y un **algoritmo de particiones (*k-means*)**, en base a su capacidad de agrupación y la calidad de los clusters obtenidos. Para ambos, se postuló un número de grupos óptimo con el cual se realizó la clasificación. Este fue obtenido mediante el método del codo (*Elbow Method*) y el de la silueta (*Silhouette Method*), con la finalidad de comparar cuál era más apropiado para determinar el número de clusters de forma visual. Los grupos creados se caracterizaron, describiendo las características que separa un grupo de otro en función de las variables del dataset.

Resultados

Datos: Estadística Descriptiva

El dataset “*spotify*” poseía 250 observaciones, con 10 variables que describían características musicales de las diferentes canciones. En la Figura 1, es posible observar que todas las variables tienen una media distinta, y la mayor parte de estas no sigue una distribución similar, incluso cuando los datos están escalados. Se destaca la amplia distribución de *mode* (*modo*) y la distribución mucho más balanceada de *valence* (*positividad musical*). Además, es notable la presencia de una gran cantidad de “*outliers*” en varias de ellas, como *speechness* (*palabras habladas*), *acousticness* (*acústica*), *instrumentalness* (*instrumental*) o *liveness* (*presencia de público*).




Figure 1: Boxplots de las variables.

Datos: Estadística Exploratoria

En la Figura 2 se observa cómo se relacionan las variables del dataset en base a su coeficiente de correlación. Es posible notar que *energy* (*energía*) y *loudness* (*intensidad sonora*) presentan una gran relación positiva, con un coeficiente de 0,66. Esto significa que, generalmente, las canciones que tienen una mayor energía poseen una mayor intensidad sonora. Por el contrario, las variables *acousticness* y *energy* presentan una relación negativa, con un coeficiente de -0,4. Esto indica que, generalmente, las canciones que son más acústicas tienen una menor energía.




Figure 2: Matriz de correlación de las variables

Ajuste y comparación de métodos

Pese a detectar una gran cantidad de “outliers” al observar los boxplots de cada variable, no se eliminaron para aplicar los métodos de clasificación. Esto se debe a que cada canción es diferente, por lo que se considera normal que existan métricas distintas que representen características musicales únicas para cada una de ellas.

Método de clustering jerárquico

En base a la comparación de coeficientes aglomerativos (Tabla 1), se determinó que el método *Ward* era el más adecuado para clasificar las canciones, ya que obtuvo el coeficiente de mayor valor.

Tabla 1. Coeficientes aglomerativos según método	
Método	Coeficiente aglomerativo
average	0.741
single	0.589
complete	0.816
ward	0.926

En la Figura 3 se observan los métodos que determinan el número óptimo de clusters para usar en la clasificación. Es posible notar que la curva del *Elbow method* no cambia abruptamente a lo largo del número de clusters (no se genera una punta del “codo” del todo clara), lo cual dificulta el establecimiento de dicho número. Sin embargo, a partir del *Silhouette Method* es mucho más fácil notar qué número de clusters es el más adecuado para usar. En este caso, se postuló el número 3, ya que este genera el mayor ancho promedio de silueta.




Figure 3: Elbow Method y Silhouette Method para el método de clustering jerárquico.

En el dendrograma presentado en la Figura 4 se observa que la clasificación generó un cluster con una mayor cantidad de observaciones (canciones), mientras que los otros dos contenían una cantidad similar de observaciones.




Figure 4: Dendrograma del clustering jerárquico

En la Figura 5 se muestra cómo el método *Ward* generó la clasificación, siendo bastante notorio que existe un solapamiento entre los grupos, con una gran cantidad de observaciones con características musicales similares entre ellos.




Figure 5: Clasificación del clustering jerárquico (ward)

Al comparar los clusters en base a las variables *energy* (Figura 6), los tres presentan una

distribución similar, generalmente alta (mayor a 0.5), siendo mucho más similares entre sí el grupo 2 y 3. Solo se observa la presencia de valores atípicos clasificados por el modelo en el grupo 1 y 3. El grupo 1 contiene canciones mucho más energéticas que los otros dos, debido a que su media relativamente es mayor. En cuanto a la comparación en base a *acousticness*, se observa que el grupo 3 presenta una distribución mucho más amplia que los otros dos, con los grupos 1 y 2 mucho más similares respecto a esta variable. Además, otros aspectos a considerar, es que el grupo 1 y 2 poseen canciones con un ritmo similar, y el grupo resulta ser el más ruidoso.




Figure 6: Boxplots de las variables clustering jerárquico

Algoritmo de particiones (k-means)

Para el algoritmo *k-means*, se determinó el mismo número de clusters que en el método de clasificación jerárquica (3), ya que también se obtuvo un mayor ancho promedio de la silueta en base al *Silhouette Method*. Además, el *Elbow Method* también resulta complicado de analizar visualmente debido a la curva que se genera (Figura 7).




Figure 7: Elbow Method y Silhouette Method para el algoritmo de particiones.

En la Figura 8 se observa de qué forma se realizó la clasificación con este método. Las observaciones se distribuyen de una forma relativamente homogénea entre los grupos, existiendo poco solapamiento.




Figure 8: Clasificación del método k-means

En este caso, los grupos creados se caracterizan por poseer diferencias respecto a *acousticness* (Figura 9). Las canciones del grupo 1 son mucho menos acústicas que las del grupo 2 y 3, y las del grupo 2 son mucho más acústicas. Respecto a *energy*, en este caso el algoritmo determinó que los grupos 1 y 2 tuvieran una distribución mucho más similar en comparación al grupo 3, la cual posee una energía más baja.




Figure 9: Boxplots de las variables por grupo k-means

Discusión

En base a los resultados, es posible corroborar que el método de clustering jerárquico no funciona bien con valores atípicos, mucho menos si es en una gran cantidad, como sucede con el dataset de spotify (Pal *et al.*, 2024). Sin embargo, debido a su naturaleza flexible, este método puede ser utilizado en combinación con otro tipo de técnicas de minería de datos (Rodríguez y Díaz, 2009).

En este caso, el método *k-means* resultó ser más adecuado para realizar la clasificación. Sin embargo, este método también es muy sensible a valores atípicos (Belyadi & Haghighat, 2021), aunque a partir del dataset de spotify generó una clasificación menos solapada en comparación al clustering jerárquico. Esto puede deberse a que este método se basa en acción reiterativa de encontrar el valor promedio de las instancias asignadas a cada centroide del cluster y volver a calcular un nuevo centroide para cada uno, moviéndolo al promedio de las instancias y reasignando cada punto de los datos a los centroides generados en función de la distancia (Belyadi & Haghighat, 2021), lo cual genera grupos bien definidos.

En cuanto a los métodos para determinar los números de cluster, el más adecuado en este caso fue el *Silhouette Method*. Esto se debe a el *Elbow Method* se basa más que nada en el

análisis visual de la “punta del codo”, el cual determina el número óptimo de clusters. Para este dataset resultó complicado de examinar de esa manera, ya que para ambos métodos de clasificación se generaron curvas muy suavizadas. En cambio, el *Silhouette Method* ofrece una determinación diferente, en la cual el número óptimo de clusters es mucho más fácil de identificar considerando este dataset.

Respecto a la caracterización de los grupos, en el algoritmo k-means es muy probable que influya en gran medida la variable *acousticness*, ya que la clasificación arrojó clusters con medias muy diferentes para cada grupo. En general, este algoritmo clasifica mejor las canciones, ya que algunas variables poseen una distribución mucho más variada para cada grupo en comparación a las que se obtienen con el método de clustering jerárquico.

Referencias bibliográficas

- Belyadi, H., & Haghighat, A. (2021). Unsupervised machine learning: clustering algorithms. In H. Belyadi & A. Haghighat (Eds.), *Machine Learning Guide for Oil and Gas Using Python* (pp. 125-168). Gulf Professional Publishing. <https://doi.org/10.1016/B978-0-12-821929-4.00002-0>
- Hernández, C., y Rodríguez, J. (2008). Preprocesamiento de datos estructurados. *Vínculos*, 4(2), 27-48. <https://revistas.udistrital.edu.co/index.php/vinculos/article/view/4123>
- Pal, S. S., Mukhopadhyay, J., & Sarkar, S. (2024). Finding hierarchy of clusters. *Pattern Recognition Letters*, 178, 7-13. <https://doi.org/10.1016/j.patrec.2023.12.009>
- Rodríguez, Y. y Díaz, A. (2009). Herramientas de Minería de Datos. *Revista Cubana de Ciencias Informáticas*, 3(3-4), 73-80. <https://www.redalyc.org/pdf/3783/378343637009.pdf>
- Ryagi, K., Rane, C., Sriram, R. & Manry, M. (2022). Unsupervised learning. In R. Pandey, S. K. Khatri, N. K. Singh, & P. Verma (Eds.), *Artificial Intelligence and Machine Learning for EDGE Computing* (pp. 33-52). Academic Press. <https://doi.org/10.1016/B978-0-12-824054-0.00012-5>