



TALLER #1. MERN. REGRESIÓN LINEAL (2024)

PREDICCIÓN DEL PESO DE HALCONES

Los estudiantes y profesores del Cornell College en Mount Vernon, Iowa, recopilaban datos durante muchos años en el refugio para halcones del lago MacBride, cerca de Iowa City, Iowa. Este dataset es un subconjunto del conjunto del set de datos original, utilizando sólo aquellas especies para las que hubo más de 10 observaciones. Se recopilaron datos de muestras aleatorias de tres especies diferentes de halcones: halcón de cola roja (Red-Tailed), halcón de brillo afilado (Sharp-Shinned) y halcón de Cooper (Cooper's).

El archivo **halcones.csv** tiene las mediciones 908, incluyendo las siguientes variables

- Species CH=Cooper's, RT=Red-tailed, SS=Sharp-Shinned
- Wing Longitud (en mm) de la pluma primaria del ala desde la punta hasta la muñeca
- Weight Peso corporal (in g)
- Culmen Longitud (en mm) de la parte superior del pico desde la punta hasta la parte carnosa del ave
- Hallux Longitud (en mm) de la garra
- Tail Medida (en mm) relativa a la longitud de la cola (según MacBride Raptor Center)

El objetivo del laboratorio es proponer y validar un modelo de regresión múltiple (2 o más variables independientes) que estime el PESO (Weight) de los halcones usando el resto de las variables como potenciales predictores.

Actividades a reportar

1. Haga un análisis exploratorio de los datos para entender los patrones más evidentes de las relaciones entre la variable dependiente (PESO, Weight) y las variables independientes (todo el resto), y las relaciones entre las variables independientes. En este análisis exploratorio puede usar estadígrafos, gráficos, tablas, etc. En resumen, utilice libremente recursos que le permitan aprender sobre la estructura de los datos **(20 puntos)**.
2. Proponga y compare **al menos 2 modelos distintos de regresión múltiple** (2 o + variables predictoras) y elija uno de ellos. Justifique su elección haciendo referencia a estadísticos de ajuste, estadígrafos del modelo, gráficos, etc. de manera que pueda seguirse el razonamiento detrás de la elección. Considere en esta sección la posibilidad de transformaciones en los datos (en Y, en X's, creación de variables nuevas, etc.) si esto resulta en un mejor modelo **(30 puntos)**.
3. **Para el modelo elegido** verifique (no es necesario corregir) los supuestos de (i) normalidad, (ii) heterocedasticidad, (iii) autocorrelación. Reporte el grado de multicolinealidad que tiene su modelo y verifique que sus residuos cumplen con el supuesto de ser variables aleatorias con esperanza igual a CERO. Calcule y reporte el sesgo (B), error cuadrático medios (ECM) y valor absoluto del residuo promedio (MAD) para la estimación del PESO **(20 puntos)**.
4. Haga un breve reporte (máximo 15 páginas sin anexos) con los resultados de las secciones 1-3 que será el documento de evaluación del taller y que incluya algunas conclusiones o una discusión de los resultados **(10 puntos para orden, presentación y redacción)**.

Considere lo siguiente:

- Recuerde (especialmente cuando haga la selección y validación de sus modelos, y cuando discuta o concluya algo) que los datos son de 3 especies distintas.
- No existe *modelos perfectos* o *el mejor modelo de todos*, sólo existen modelos buenos y modelos malos.
- El valor de R^2 no debe ser un factor excesivamente relevante en la selección del modelo final, la lógica del modelo y la confiabilidad respecto de los coeficientes β_i deben ser más importantes
- No considere en esta ocasión la selección de una muestra de entrenamiento y una muestra de validación.

Plazo de entrega viernes 12 –abril 23:55 hrs.



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
FACULTAD DE AGRONOMÍA Y SISTEMAS NATURALES
DEPARTAMENTO DE ECOSISTEMAS Y MEDIO AMBIENTE

Sube tus respuestas al sitio web del curso en CANVAS (Módulo de Laboratorios) antes de la hora de entrega. Se contemplará un plazo adicional de 12 horas adicionales para recepción (hora de cierre), pero aquellas respuestas que sean ingresadas después de la hora de entrega y antes del período de cierre se les descontará medio punto de la nota final por cada 1 hora entera de atraso. Es decir, si entregas con 2,5 horas de atraso y tienes un 6,4 en tu laboratorio, la nota que te corresponde es un 5,4.