



LABORATORIO #3. MERN. APRENDIZAJE SUPERVISADO / CLASIFICACIÓN (2024)

PREDICCIÓN DE SOBREVIVENCIA EN EL TITANIC

El dataset titanic.csv contiene información del trágico accidente que sucedió un 31 de marzo de 1909. Se describe el dataset a continuación:

Variable	Definición	Código
survival	sobrevivencia	0 = No, 1 = Yes
pclass	Clase	1 = Primera, 2 = Segunda, 3 = Tercera clase
sex	Sexo	
Age	Edad	
sibsp	# hermanos / cónyuge a bordo	
parch	# padres / hijos a bordo	
ticket	número del boleto	
fare	Precio	
cabin	Número cabina	
embarked	Puerto donde se embarcó C = Cherbourg, Q = Queenstown, S = Southampton	

El objetivo del ejercicio es proponer y validar un método que permita clasificar la sobrevivencia de los pasajeros (0 = no, 1 = yes) sobre la base de todas o algunas de las variables. Algunas variables no serán de utilidad, por lo que se debe hacer estadística descriptiva y selección de variables en base a suposiciones.

Tarea

Proponer y evaluar el poder de predicción de un método de clasificación supervisada que permita clasificar la sobrevivencia.

1. Seleccione aleatoriamente una muestra para entrenar el algoritmo y una muestra de validación/testeo. Exprese en su respuesta explícitamente la porción de datos de entrenamiento y validación (en %) utilizada.
2. Evalúe los 3 métodos de clasificación supervisada revisados hasta el momento, en el curso, para resolver este problema (K-nn, regresión logística y Bayes Ingenuo). Aplíquelos sobre los datos de entrenamiento considerando todos los predictores. Reporte el k, los coeficientes significativos del GLM logit y las probabilidades a priori y las medias y desviaciones por clase para cada predictor del Bayes Ingenuo.
3. Pruebe los 3 métodos en la muestra de validación y seleccione uno de ellos basándose en métricas que permitan medir la capacidad del método para clasificar en una muestra independiente de objetos. Discuta sobre modelos utilizados y justifique su elección no solo pensando en términos estadísticos, sino que también prácticos y computacionales.
4. Discuta sobre el uso de diferentes valores de K para K-nn.

Notas:

- a. Apóyese en la matriz de confusión y sus indicadores derivados, más curva ROC y Área Bajo la Curva. Reporte resultados.
- b. Piense en si el problema requiere que ambos grupos sean clasificados con el mismo grado de certeza.

Entregue un documento con el desarrollo de los puntos 2 y 3. Reporte tablas asociadas las asignaciones de clasificación por cada método y determine los umbrales de corte por cada uno de ellos para resolver el problema de forma satisfactoria.

Plazo de entrega Martes 7 – Junio 23:55 hrs.

Sube tus respuestas al sitio web del curso en CANVAS (Módulo de Laboratorios) antes de la hora de entrega. Se contemplará un plazo adicional de 12 horas adicionales para recepción (hora de cierre), pero aquellas respuestas que sean ingresadas después de la hora de entrega y antes del período de cierre se les descontará medio punto de la nota final por cada 1 hora entera de atraso. Es decir, si entregas con 2,5 horas de atraso y tienes un 6,4 en tu laboratorio, la nota que te corresponde es un 5,4.