



TALLER #4. MERN. APRENDIZAJE NO SUPERVISADO (2024)

SPOTIFY

El objetivo de este Taller es utilizar análisis de conglomerados para separar grupos de canciones en base a sus características musicales. El conjunto de datos **dataset_spotify.csv** contiene las siguientes variables (aparte de las canciones):

1. **danceability:**
Describe lo adecuada que es una pista para bailar basándose en una combinación de elementos musicales. Un valor de 0,0 es el menos bailable y 1,0 el más bailable.
2. **energy:**
Es una medida de 0,0 a 1,0 y representa una medida perceptiva de intensidad y actividad. Normalmente, las pistas energéticas son rápidas, ruidosas y ruidosas. Por ejemplo, el death metal tiene una energía alta, mientras que Bach tiene una puntuación baja en la escala.
3. **loudness:**
Decibeles. El rango va de -60 a 0 db
4. **mode:**
Modalidad (mayor o menor) de una pista, el tipo de escala del que se deriva su contenido melódico. Mayor se representa con 1 y menor con 0.
5. **speechiness:**
Describe la presencia de palabras habladas en una pista. Cuanto más exclusivamente hablada sea la grabación (por ejemplo, programa de entrevistas, audiolibro, poesía), más se acercará a 1,0 el valor del atributo.
6. **acousticness:**
Medida de confianza de 0,0 a 1,0 sobre si la pista es acústica. 1,0 representa una confianza alta en que la pista es acústica.
7. **instrumentalness:**
Cuanto más se acerque el valor de instrumental a 1,0, mayor será la probabilidad de que la pista no contenga voces. Los valores superiores a 0,5 representan pistas instrumentales, pero la confianza es mayor a medida que el valor se acerca a 1,0.
9. **liveness:**
Detecta la presencia de público en la grabación. Los valores de liveness más altos representan una mayor probabilidad de que la pista se haya interpretado en directo. Un valor superior a 0,8 proporciona una gran probabilidad de que la pista sea en directo.
10. **valence:**
Medida de 0,0 a 1,0 que describe la positividad musical que transmite una pista. Las pistas con valencia alta suenan más positivas (felices o alegres), mientras que las pistas con valencia baja suenan más negativas (tristes o deprimidas).
11. **tempo** : En terminología musical, el tempo es la velocidad o el ritmo de una pieza determinada y se deriva directamente de la duración media de los tiempos. La unidad es BPM.

El objetivo del ejercicio es proponer y validar un método que permita separar las canciones en grupos usando algún algoritmo de clustering / aglomeramiento.

Tarea

Separar las canciones en un número de grupos a determinar y caracterizar cada uno de los grupos en términos de cuáles son las características que lo diferencian del resto de los grupos propuestos

1. Haga un análisis previo (pre-proceso) para verificar presencia de outliers, correlaciones o dependencias entre las variables si es que esto ayuda al proceso de clustering.
2. Use un método de **clustering jerárquico** y postule un número de grupos usando este algoritmo.
3. Caracterice los grupos propuestos, detallando porque postula ese número de grupos y describa las características que según su opinión separa a este grupo de los otros. Asigne una etiqueta a cada grupo propuesto.
4. Use un **algoritmo de particiones** (k-means) y postule un número de grupos usando este algoritmo.
5. Caracterice los grupos propuestos, detallando porque postula ese número de grupos y describa las características que según su opinión separa a este grupo de los otros.



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
FACULTAD DE AGRONOMÍA E INGENIERÍA FORESTAL
DEPARTAMENTO DE ECOSISTEMAS Y SISTEMAS NATURALES

6. Compare las agrupaciones de ambos enfoques.

Plazo de entrega 25 de Junio- 23:55 hrs.

Sube tus respuestas al sitio web del curso en CANVAS (Módulo de Laboratorios) antes de la hora de entrega. Se contemplará un plazo adicional de 12 horas adicionales para recepción (hora de cierre), pero aquellas respuestas que sean ingresadas después de la hora de entrega y antes del período de cierre se les descontará medio punto de la nota final por cada 1 hora entera de atraso. Es decir, si entregas con 2,5 horas de atraso y tienes un 6,4 en tu laboratorio, la nota que te corresponde es un 5,4.